

머신러닝 Feature Engineering 파이프라인 보고서

데이터셋: Titanic Dataset / 목표: 생존 여부 예측(Classification)

1. 과제 개요

본 과제는 실제 공개 데이터셋을 활용하여 데이터 탐색, 결측치 처리, 범주형 인코딩, 스케일링, 파생 변수 생성, 변수 선택, 모델 학습 및 평가까지 전체 머신러닝 파이프라인을 구현하고 성능 차이를 비교하는 것을 목표로 한다.

2. 데이터셋 소개

본 보고서는 Titanic Dataset 을 사용한다. 해당 데이터셋은 승객의 성별, 나이, 객실 등급, 운임, 동승 가족 수 등의 정보를 바탕으로 생존 여부를 예측하는 이진 분류 문제이다.

데이터 shape: 코드 실행 결과 입력 예) (891, 12)

3. 컬럼 설명

컬럼명	설명	변수 유형
PassengerId	승객 고유 ID	식별자
Survived	생존 여부(0=사망, 1=생존)	타겟
Pclass	객실 등급	수치/순서형
Name	승객 이름	문자열
Sex	성별	범주형
Age	나이	수치형
SibSp	형제/배우자 수	수치형
Parch	부모/자녀 수	수치형
Ticket	티켓 번호	문자열
Fare	운임	수치형
Cabin	객실 번호	범주형/문자열
Embarked	승선 항구	범주형

4. EDA 결과

결측치 분석: Age, Cabin, Embarked 등의 결측치를 확인하고 결측 비율을 산출한다. Cabin 은 결측 비율이 높아 직접 사용하기보다 제거하거나 별도 파생 변수화하는 전략을 고려할 수 있다.

이상치 분석: Fare 는 일부 고가 운임 승객으로 인해 오른쪽으로 긴 분포를 보이며, Boxplot 에서 이상치 후보가 확인될 수 있다.

타겟 분포: Survived 의 0/1 비율을 확인하여 클래스 불균형 여부를 판단한다.

보고서에는 results/figures 폴더의 Histogram, Boxplot, Heatmap, Countplot 이미지를 삽입한다.

5. Feature Engineering 과정

FamilySize = SibSp + Parch + 1 : 가족 동반 규모를 나타내는 변수

IsAlone : FamilySize 가 1 인 경우 1, 아니면 0

FarePerPerson = Fare / FamilySize : 가족 수에 따른 1 인당 운임

AgeGroup : 나이를 Child/Teen/Young/Adult/Senior 구간으로 변환

Title : 이름에서 Mr, Miss, Mrs 등의 호칭을 추출

6. 실험 설계

실험	결측치 처리	인코딩	스케일링	Feature Selection
Base	없음	없음	없음	없음
Exp-1	Mean	One-Hot	StandardScaler	X
Exp-2	Median	Label/Ordinal	MinMaxScaler	O
Exp-3	Most Frequent	One-Hot	RobustScaler	O

7. 모델 학습 및 평가

Logistic Regression 과 Random Forest Classifier 를 최소 비교 모델로 사용한다. 평가지표는 Accuracy, Precision, Recall, F1-score, ROC-AUC 를 사용한다.

성능 비교표는 results/metrics/experiment_results.csv 실행 결과를 기반으로 작성한다.

8. 최종 결론 작성 방향

가장 높은 F1-score 와 ROC-AUC 를 보인 조합을 최종 모델로 선정한다. One-Hot Encoding 은 범주 간 순서가 없는 데이터에 적합하지만 차원이 증가할 수 있으며, Label/Ordinal Encoding 은 차원 증가가 적지만 범주 간 잘못된 순서 관계를 만들 수 있다. Feature Selection 은 불필요한 변수를 제거하여 과적합 완화에 기여할 수 있으나, 데이터와 모델에 따라 성능 향상이 항상 보장되지는 않는다. 스케일링은 Logistic Regression 같은 선형 모델에 더 큰 영향을 미치며, Random Forest 는 상대적으로 스케일링 영향이 작을 수 있다.

9. GitHub 주소

GitHub Repository URL: 여기에 본인 GitHub 주소 입력